

## Chapter 7: Non-linear Regression

### 7.0 Overview

- **线性模型局限性:** 均值响应必须是输入的线性函数, 这在实践中通常不成立。
- **核心思想:** 基函数法 (basis function approach), 使用输入变量的派生输入 (derived inputs)。
- **重要模型 (部分):** 多项式回归、阶梯函数、回归样条、平滑样条、局部回归、广义可加模型 (GAM)。

### 7.1 Polynomial Regression

- **模型形式:** 是一个多重线性回归模型, 输入为  $(x_i, x_i^2, \dots, x_i^p)$ 。
- **问题/缺点:** 难以确定合适的阶数  $p$ : 难以拟合局部高度变化的函数。
- **模型选择技巧:** 使用方差分析 (ANOVA) 比较不同阶数的模型。

多项式回归模型 ( $p$  阶):

$$y_i = \beta_0 + \beta_1 x_i + \beta_2 x_i^2 + \dots + \beta_p x_i^p + \epsilon_i$$

广义线性模型 (Generalized linear model, GLM) 公式:

$$E(Y|X) = g(X^T \beta)$$

带多项式回归的逻辑模型 (二元响应):

$$p(y_i = 1|x_i) = \frac{\exp(\beta_0 + \beta_1 x_i + \dots + \beta_p x_i^p)}{1 + \exp(\beta_0 + \beta_1 x_i + \dots + \beta_p x_i^p)}$$

### 7.2 Step Functions

- **概念:** 分段常数函数 (Piecewise constant functions)。
- **缺点:** 非光滑, 甚至不连续; 分割点 (cutpoints) 的数量和位置难以确定。

### 7.3 Regression Splines

- **概念:** 分段多项式函数, 切分点称为结点 (knots)。
  - **样条函数:** 阶数  $d$  的样条函数在结点处具有直到  $d-1$  阶的连续导数。
  - **三次样条 (Cubic spline):** 分段三次多项式, 在结点处连续且具有连续的一阶和二阶导数。
  - **自然样条 (Natural spline):** 在边界附近施加进一步限制, 表现通常优于三次样条。
  - **优点:** 捕捉局部变化; 边界行为比多项式回归更好。
- 三次样条模型 (截断幂基,  $d=3$ ):

$$y_i = \beta_0 + \beta_1 x_i + \beta_2 x_i^2 + \beta_3 x_i^3 + \sum_{k=1}^K \gamma_k (x_i - \xi_k)_+^3 + \epsilon_i$$

截断幂函数:

$$h(x, \xi) = (x - \xi)_+^d$$

### 7.4 Smoothing Splines

- **平滑参数 ( $\lambda$ ):** 控制粗糙度惩罚。
- **解:** 平滑样条问题的解是一个在每个  $x_i$  处都有结点的自然三次样条。

最小化目标 (惩罚残差平方和):

$$\min_f \left\{ \frac{1}{n} \sum_{i=1}^n (y_i - f(x_i))^2 + \lambda \int_a^b [f''(x)]^2 dx \right\}$$

平滑参数  $\lambda$  的极限行为:

- $\lambda \rightarrow \infty$ :  $f$  为线性最小二乘拟合。
- $\lambda \rightarrow 0$ :  $f$  在每个  $x_i$  处插值  $y_i$ 。

### 7.5 Local Regression

- **核心:** 在目标点  $x_0$  附近进行加权最小二乘拟合。
- **权重  $K_{i0}$ :** 由核函数 (Kernel function,  $k(t)$ ) 和带宽  $h$  决定。

局部多项式回归目标:

$$\sum_{i=1}^n K_{i0} (y_i - \beta_0 - \beta_1(x_i - x_0) - \dots - \beta_p(x_i - x_0)^p)^2$$

权重  $K_{i0}$  公式:

$$K_{i0} = \frac{1}{h} k\left(\frac{x_i - x_0}{h}\right)$$

### 7.6 Generalized Additive Model (GAM)

- **特点:** 保持可加性, 但允许每个预测变量使用任意非线性函数  $f_j$ 。
- **拟合方法:** 反向拟合算法 (Backfitting algorithm)。

GAM (回归) 模型公式:

$$Y_i = \beta_0 + \sum_{j=1}^p f_j(X_{ij}) + \epsilon_i$$

GAM (GLM) 模型公式:

$$E(Y|X) = g\left(\beta_0 + \sum_{j=1}^p f_j(X_{ij})\right)$$

### 7.7 Reproducing Kernel Hilbert space (RKHS)

- **非线性扩展:**  $Y = f(X) + \epsilon = \beta^\top \Phi(X) + \epsilon$ 。
- **表示定理 (Representer Theorem):** 核岭回归的解  $f^*(\cdot)$  必须是训练数据的核函数  $k(x_i, \cdot)$  的加权和。

核岭回归 (Kernel Ridge Regression) 目标:

$$\min_{f \in \mathcal{H}_k} \frac{1}{n} \sum_{i=1}^n (y_i - f(x_i))^2 + \lambda \|f\|_{\mathcal{H}_k}^2$$

核岭回归 (向量形式) 最小化目标:

$$\min_{\alpha} \|\mathbf{y} - \mathbf{K}\alpha\|^2 + \lambda \alpha^\top \mathbf{K}\alpha$$

## Chapter 8: Tree-based Methods

### 8.0 Basic Concepts

- **数据建模文化 (Data modelling culture):** 假设数据由给定的随机数据模型生成 (例如: 线性回归)。
- **算法建模文化 (Algorithmic modelling culture):** 将数据生成机制视为未知, 使用算法模型 (例如: 决策树、神经网络)。
- **决策树 (Decision Tree):** 将特征空间递归地二分 (recursively partition) 成不重叠的区域  $R_1, R_2, \dots, R_J$ 。
- **优点:** 易于解释和可视化; 能自动处理定性预测变量 (qualitative predictors)。
- **缺点:** 预测准确性通常低于其他回归和分类方法; 对数据的小变化非常不稳定 (high variance)。

### 8.1 Regression Trees

- **预测:** 对落入区域  $R_j$  的观测, 预测值等于该区域内训练响应的平均值  $c_j$ 。
- **目标:** 寻找  $R_1, \dots, R_J$  以最小化残差平方和 (RSS)。

最小化目标 (残差平方和, RSS):

$$\sum_{j=1}^J \sum_{i \in R_j} (y_i - \hat{y}_{R_j})^2$$

### 8.2 Classification Trees

- **预测:** 对落入区域  $R_j$  的观测, 预测为该区域内最常出现的类别 (majority class)。
- **分裂标准:** 最小化错误分类率 (Misclassification Error Rate)、Gini Index (基尼指数) 或 Cross-Entropy (交叉熵/信息熵)。

错误分类率 (Misclassification Error Rate):

$$E = 1 - \max_k (\hat{p}_{jk})$$

基尼指数 (Gini Index):

$$G = \sum_{k=1}^K \hat{p}_{jk}(1 - \hat{p}_{jk})$$

交叉熵 (Cross-Entropy):

$$D = - \sum_{k=1}^K \hat{p}_{jk} \log(\hat{p}_{jk})$$

### 8.3 Tree Pruning

- **问题:** 构建完整的树通常导致过拟合 (overfit)。
- **方法:** 成本复杂度剪枝 (Cost Complexity Pruning), 也称为弱链接剪枝 (Weakest Link Pruning)。
- **过程:**
  1. 构造一个非常大的树  $T_0$ 。
  2. 使用成本复杂度剪枝获得一个子树序列  $T_\alpha$ 。
  3. 使用交叉验证 (CV) 或独立测试集选择最优  $\alpha$ 。

成本复杂度准则 (Cost Complexity Criterion):

$$\sum_{m=1}^{|T|} \sum_{i: x_i \in R_m} (y_i - \hat{y}_{R_m})^2 + \alpha |T|$$

### 8.4 Ensemble Methods

Bagging (Bootstrap Aggregation)

- **核心:** 通过多次有放回抽样训练多个决策树, 然后取平均 (回归) 或多数投票 (分类) 以降低方差。
- **袋外估计 (OOB Estimation):** 使用未被选入当前 Bootstrap 样本的观测进行预测, 计算泛化误差。
- **变量重要性 (Variable Importance):** 通过计算某个特征引起的 RSS/Gini Index 总减少量来衡量。

Random Forests

- **核心:** 在 Bagging 基础上, 每次分裂时仅考虑  $m$  个随机子集变量。
- **参数  $m$ :** 通常  $m \approx \sqrt{p}$  (分类) 或  $m = p/3$  (回归)。
- **效果:** 进一步解耦单个树, 比 Bagging 方差更低。

Boosting

- **核心:** 顺序拟合弱学习器; 每棵新树拟合前树的残差。
- **参数:**
  - 树的数量  $M$ : 大  $M$  易过拟合。
  - 学习率  $\lambda$ : 通常很小 (0.01 或 0.001)。
  - 树深度  $d$ : 通常  $d = 1$  (stump) 效果好。

Boosting (回归) 算法:

$$f(x) \leftarrow f(x) + \lambda \hat{f}^b(x)$$

## Chapter 9: Support Vector Machines

### 9.1 Maximal Margin Classifier

- **概念:** 找到超平面使其与最近样本的间隔最大化。
  - **适用条件:** 仅线性可分二分类。
  - **支持向量:** 落在间隔边界上的点。
- 超平面定义:

$$f(x) = x^T \beta + \beta_0 = 0$$

优化目标:

$$\max_{\beta, \beta_0, M} M \quad \text{s.t.} \quad \sum_{j=1}^p \beta_j^2 = 1, \quad y_i(x_i^T \beta + \beta_0) \geq M$$

### 9.2 Support Vector Classifier

- **核心:** 允许少量错分或落入间隔内。
  - **松弛变量  $\xi_i$ :** 衡量违反程度。
  - **成本参数  $C$ :** 控制间隔与误分类权衡。
- 优化目标:

$$\min \left\{ \frac{1}{2} \|\beta\|^2 + C \sum \xi_i \right\} \quad \text{s.t.} \quad y_i(x_i^T \beta + \beta_0) \geq 1 - \xi_i, \quad \xi_i \geq 0$$

### 9.3 Support Vector Machine

- **核心:** 核方法实现非线性边界。
  - **核函数  $K(x_i, x_{i'})$ :** 计算高维内积。
  - **核技巧:** 避免显式高维映射。
- 决策函数:

$$f(x) = \text{sign} \left( \sum_{i \in \mathcal{S}} \alpha_i y_i K(x, x_i) + \beta_0 \right)$$

常用核函数:

- **Linear:**  $K = \sum x_{ij} x_{i'j}$
- **Polynomial:**  $K = (1 + \sum x_{ij} x_{i'j})^d$
- **RBF:**  $K = \exp(-\gamma \sum (x_{ij} - x_{i'j})^2)$

### 9.5 SVMs with More Than 2 Classes

- **One-vs-One:** 训练  $K(K-1)/2$  个分类器, 多数投票。
- **One-vs-All:** 训练  $K$  个分类器, 取最高分数。

### 9.6 Relation to Logistic Regression

- **共同框架:** 损失 + 惩罚。
- **Logistic:** Log-Likelihood Loss + L2/L1。
- **SVC:** Hinge Loss + L2。

Hinge Loss:

$$L(y, f(x)) = \max(0, 1 - yf(x))$$

## Chapter 10: Unsupervised Learning

### 10.0 Overview

- **定义:** 无响应变量  $Y$ 。
- **目标:** 发现数据结构。
- **主要方法:** 降维 (PCA)、聚类 (K-means, Hierarchical)。

### 10.1 Principal Component Analysis

- **核心:** 低维表示捕获最大方差。
  - **第  $m$  个主成分:** 最大方差且与前  $m-1$  个不相关。
- 第  $m$  个主成分:

$$Z_{im} = \sum_{j=1}^p \phi_{mj} X_{ij}$$

PVE:

$$PVE_m = \frac{\lambda_m}{\sum \lambda_l}$$

Cumulative PVE:

$$\frac{\sum_{l=1}^m \lambda_l}{\sum \lambda_l}$$

选择  $M$ : Elbow / Scree Plot。

### 10.2 Clustering Analysis

K-Means Clustering

目标:

$$\min \sum_{k=1}^K \sum_{i, i' \in C_k} \|x_i - x_{i'}\|^2$$

Hierarchical Clustering

- **特点:** 产生树状图, 无需预设  $K$ 。
- **链接方式:** Complete, Average, Single, Centroid。

## Chapter 11: Semi-Supervised and Self-Supervised Learning

### 11.1 Semi-Supervised Learning

- **定义:** 少量标签 + 大量未标签数据。

### 11.2 SSL Assumptions

- **Smoothness:** 近距离点标签相似。
- **Cluster:** 同簇同类, 决策边界低密度区。
- **Manifold:** 数据位于低维流形。

### 11.4 SSL Algorithms

Self-Training

逐步用高置信伪标签扩展标签集。

Co-Training

两个独立视图互相生成伪标签。

## Graph-based SSL

标签传播 / 扩散。

Graph Laplacian:

$$\mathcal{L} = D - W$$

## 11.8 Self-Supervised Learning

- **核心:** 前置任务产生伪标签预训练表示。

Triplet Loss:

$$L = \max(0, \|f(A) - f(P)\|^2 - \|f(A) - f(N)\|^2 + \alpha)$$

# Chapter 12: Intro to Deep Learning and Deep Generative Models

## 12.1 Intro to Deep Learning

- **核心:** 多层神经网络自动学习特征。
- **Universal Approximation Theorem:** 单隐藏层足以逼近任意连续函数。

## 12.2 Simple Neural Network

神经元输出:

$$A_k = g\left(\beta_{0k} + \sum X_j \beta_{jk}\right)$$

## 12.3 Activation Functions

Sigmoid, Tanh, ReLU。

## 12.4 Loss and Optimization

反向传播 + 梯度下降。

更新:

$$W := W - \alpha \nabla J(W)$$

## 12.5 Convolutional Neural Networks

卷积 + 池化。

## 12.6 Recurrent Neural Networks

隐藏状态  $h_t = f_W(h_{t-1}, x_t)$ ; LSTM/GRU 解决梯度问题。

## 12.7 Deep Generative Models

VAE

Encoder  $\rightarrow$  Latent  $z \rightarrow$  Decoder。

GAN

目标:

$$\min_G \max_D E[\log D(x)] + E[\log(1 - D(G(z)))]$$

## 12.9 Transformer

自注意力 + 多头注意力 + 位置编码。